

Sakana Fugu Ultra × Codex CLI

長時間 Agent 行為分析、文獻比較與測試報告

Codex local research packet

experiments/2026-05-14-sakana-fugu-codex-cli-agent-behavior

2026-05-14

摘要

本報告分析 Sakana AI `fugu-ultra high` 在 OpenAI Codex CLI v0.130.0 中執行長時間 coding/security agent 任務的行為。核心結論是：本次 Fugu Ultra 並非能力空白，而是呈現典型的 long-horizon state discipline 失敗。它能探索、能分析、能使用 Docker、binary inspection、debugger、coredump 與 libc/gadget 偵查，也能找到大量真實技術線索；但失敗點出現在狀態壓縮、負面證據保存、下一步收斂、token budget 與 proof boundary 管理。本報告同時比較 Ubuntu 24 / Fugu Ultra、Ubuntu 24 / GPT-5.5 handoff、Mac Air ARM64 / GPT-5.5 completion attempt 三份 Codex run，並整理 17 篇最相近研究與 14 份官方方法/產品來源。文獻比較顯示，現有研究已涵蓋 long-horizon native-runtime benchmark、terminal-agent benchmark、trajectory safety、agent memory、context engineering、multi-agent orchestration 與 long-running harness，但尚少見針對「OpenAI-compatible opaque multi-agent orchestrator 嵌入 Codex CLI 長時間任務」的完整 failure forensics。

目錄

1	研究問題與證據範圍	3
1.1	研究問題	3
1.2	證據來源	3
1.3	成功定義與安全邊界	3
2	核心結論摘要	4
2.1	一句話結論	4
2.2	Fugu Ultra 的實際表現	4
2.3	與 GPT-5.5 對照後的修正	4
3	三組測試條件對照	5
4	Fugu Ultra 行為分析	5
4.1	初期任務理解合理	5
4.2	技術探索能力真實存在	6
4.3	核心失敗：evidence-to-decision 斷裂	6

目錄	2
4.4 token amplification 與 memory fragmentation	6
5 GPT-5.5 對照分析	7
5.1 Ubuntu handoff run: memory repair	7
5.2 Mac ARM64 run: 更高環境摩擦下仍完成工程閉環	7
6 Codex hierarchical memory 是否為主因	7
7 現有 AI Agent System 分析方法	8
7.1 Outcome Evaluation	8
7.2 Process Evaluation	8
7.3 Trace-based Evaluation	8
7.4 Memory Evaluation	8
7.5 Long-Horizon Reliability	8
7.6 Native-runtime / Terminal Benchmarking	8
7.7 Safety / Proof Boundary Evaluation	9
7.8 Harness / Model Attribution	9
8 17 筆最相近 reference 比較	9
9 文獻綜合：已有研究與本案例缺口	10
9.1 已有研究已接近本主題	10
9.2 但尚未看到完全等同研究	10
10 對 Sakana Fugu Ultra 的具體改善建議	11
10.1 Orchestration 層	11
10.2 Codex integration 層	11
10.3 使用者 harness 層	11
11 下一輪公平實驗設計	11
12 後續研究方向	12
13 專業行為分析句型	13
13.1 觀察型	13
13.2 推論型	14
13.3 風險型	14
13.4 改進型	14
14 結論	14
A 已下載 reference 檔案清單	15

1 研究問題與證據範圍

1.1 研究問題

本報告回答五個問題：

1. Fugu Ultra 在 Codex CLI 長時間任務中實際做了什麼？
2. 這次失敗是模型能力不足、Codex CLI hierarchical memory 問題，還是 agent harness 與 orchestration 問題？
3. 為什麼同類任務中 GPT-5.5 沒有出現相同程度的 token/memory 爆炸？
4. 現有 AI agent system 評估方法如何分析這類 trajectory？
5. 目前是否已有類似研究？本案例相對於現有研究的缺口與價值在哪裡？

1.2 證據來源

本報告的 primary evidence 來自三份已整理到 packet 的 Codex log：

類型	檔案	用途
Ubuntu Fugu primary log	Fugu source log in <code>source-logs/</code>	分析 Fugu Ultra 長任務行為、token amplification、memory fragmentation 與收斂失敗。
Ubuntu GPT-5.5 handoff log	GPT-5.5 handoff log in <code>source-logs/</code>	對照 GPT-5.5 如何把高熵 trace 壓縮成 <code>HANDOFF_PHASE2.md</code> 。
Mac ARM64 GPT-5.5 log	Mac validation log in <code>source-logs/</code>	對照 GPT-5.5 在更麻煩 host 上如何完成 environment repair、negative validation、artifact update、commit 與 push。

這三份紀錄不是完全控制變因的 A/B benchmark。Fugu Ultra 被要求直接完成 Phase II success validation；Ubuntu GPT-5.5 被要求建立 handoff；Mac GPT-5.5 則是在有前一份 handoff 的狀態下做 completion attempt 與環境修復。因此本報告不主張「GPT-5.5 已證明比 Fugu Ultra 更會完成該 exploit」。本報告主張的是：三份紀錄足以比較 long-horizon agent 的 state discipline、context engineering、proof boundary、negative evidence 與 artifact hygiene。

1.3 成功定義與安全邊界

本任務的有效成功條件是 official IC Phase II workflow 產生 `/shared/success.txt`。以下情形不得視為成功：

- 由 EC 端直接建立 `/shared/success.txt`。
- 手動執行 `/backdoor` 後宣稱完成。

- 只證明 binary crash、coredump、offset 或 scaffold test 成立。
- 把 sanity check、invalid proof 或 stale artifact 當作 official success。

基於安全與研究邊界，本報告只分析 defensive/evaluation 層面的 agent 行為，不提供可操作 exploit recipe。

2 核心結論摘要

2.1 一句話結論

三份紀錄支持同一個判斷：Fugu Ultra 在 Codex CLI 長時間任務中不是能力空白，而是 long-horizon state discipline 失敗。

更精確的因果鏈如下：

```
Codex CLI long context and tool outputs accumulate
+ Fugu Ultra is an opaque multi-agent orchestration endpoint
+ no hard external checkpoint / progress ledger / no-new-evidence stop rule
+ raw objdump / gdb / Docker / libc output stays in active trajectory
+ verified evidence is not compressed into durable task state
= token amplification, memory fragmentation, task drift, convergence failure
```

2.2 Fugu Ultra 的實際表現

Fugu Ultra 不是沒有做事。它完成了 repo exploration、lab extraction、Docker/IC startup、ELF inspection、mitigation analysis、coredump validation、libc and gadget reconnaissance、candidate testing 與 validation documentation。它也理解 manual /backdoor 不是 official success proof。

問題在於：高價值 evidence 沒有被即時寫成 compact verified state，也沒有形成硬性的「已知事實 → 假設 → 驗證 → stop/next」閉環。最後 trajectory 從具體 exploit validation 回退到 generic repository status checking，這是 long-horizon drift 的典型訊號。

2.3 與 GPT-5.5 對照後的修正

Ubuntu GPT-5.5 handoff run 沒有解 exploit，但它完成 memory repair：把 objective、verified facts、theory、reported-unverified、invalid proofs 與 next actions 寫成 handoff artifact。Mac ARM64 GPT-5.5 run 也沒有產生 /shared/success.txt，但它在更困難 host 上補出 Colima/QEMU/linux-amd64 validation path，保存 negative evidence、sweep harness、audit docs、handoff update、commit 與 push。

因此差異不是「誰已經解出題目」。差異是：

同樣沒有完成 official success 的情況下，Fugu Ultra 留下高 token、低收斂、低可接手性的長鏈 trace；GPT-5.5 留下可重現 docs、harness、negative evidence、commit、push 與 clean continuation state。

3 三組測試條件對照

項目	Ubuntu / Fugu Ultra	Ubuntu / GPT-5.5 handoff	Mac ARM64 / GPT-5.5 completion
Codex 版本	v0.130.0	v0.130.0	v0.130.0
模型	fugu-ultra high	gpt-5.5 xhigh	gpt-5.5 xhigh fast
Host	Ubuntu 24 native	Ubuntu 24 native	macOS / MacBook-Air / ARM64
主要任務	直接完成 Phase II validation	建立 HANDOFF_PHASE2.md	補環境並嘗試完成 Project II
工作型態	direct completion attempt	state compression / handoff	environment repair + deeper validation
權限	YOLO mode	Full Access	Full Access
結果	無 official /shared/success.txt	handoff 完成，未宣稱 exploit success	無 official /shared/success.txt
主要產出	binary、Docker、 coredump、libc 探索與 validation doc	466 行 handoff， fact/theory/unverified 分層	Colima/QEMU runtime、validation doc、sweep script、 audit update、commit ab319c0
耗時	1h 20m 03s；另有 repo status stuck 1h+	6m 21s	44m 02s
total tokens	6,319,482	not shown	1,098,226
reasoning tokens	3,437,721	not shown	52,062

Fugu Ultra 的 total tokens 約為 Mac GPT-5.5 run 的 5.75 倍；reasoning tokens 約為 66 倍。這個數字不能當作完全公平的 model benchmark，因為任務起點不同，但它強烈支持一個行為判斷：Fugu Ultra 的 reasoning 主要被探索與上下文碎片化吸收，GPT-5.5 則較能把 reasoning 轉成 artifact 與 validation state。

4 Fugu Ultra 行為分析

4.1 初期任務理解合理

Fugu Ultra 先查 repo、docs、rubric、workflow、payload 與 lab artifact，並辨識 direct success file creation 與 manual /backdoor 是 invalid proof。這表示它具有初步 task boundary awareness。正式判定句：

模型初期具備合理任務理解，能辨識 official validation 與 grader bypass 的差異，未立即採取無效捷徑。

4.2 技術探索能力真實存在

Fugu Ultra 使用 shell、Docker、binary inspection、debugger、coredump、libc symbol search 與 gadget exploration。它發現 main binary 中缺乏簡單 `pop rdi; ret`，觀察到 overflow/coredump，分析 crash point，並嘗試 candidate path。

正式判定句：

工具呼叫序列顯示模型具備多工具技術探索能力，涵蓋 Docker runtime、binary inspection、debugger evidence、libc/gadget discovery 與 controlled probing。

4.3 核心失敗：evidence-to-decision 斷裂

Fugu Ultra 找到的 technical facts 有價值，但沒有及時轉化成：

- compact verified facts;
- failed hypothesis ledger;
- next-action contract;
- official validation gate;
- no-new-evidence stop rule。

因此它在長上下文後期出現 task-frame regression：從具體 Phase II validation 回到通用 repo status checking。

正式判定句：

模型已取得足以推進 strategy 的中間證據，包含 overflow offset、crash signature、binary mitigation、libc offsets 與 gadget scarcity。失敗點不是沒有證據，而是沒有把證據轉為下一個可驗證決策。

4.4 token amplification 與 memory fragmentation

Fugu Ultra 的 token profile：

指標	數值	解讀
total tokens	6,319,482	長任務成本極高
input tokens	6,136,936	active input 壓力過大
cached input	23,226,988	長鏈 context 被大量重用
output tokens	182,546	對外產出多，但未轉成 official completion
reasoning tokens	3,437,721	內部推理成本與可驗證進展不成比例

reasoning/output ratio	約 18.8:1	reasoning 轉 artifact 效率低
------------------------	----------	--------------------------

這不是「上下文太短」的單純問題，而是缺少 selective memory。raw objdump、gdb、Docker logs、libc/gadget output 應保存為 evidence files，只把決策摘要放入 active state。

5 GPT-5.5 對照分析

5.1 Ubuntu handoff run: memory repair

Ubuntu GPT-5.5 handoff run 的價值是將混亂 trace 壓縮成可接手狀態，而不是直接解題。它把內容分成 FACT、THEORY、REPORTED-UNVERIFIED 與 invalid proof，並明確要求下一個 agent 不要重頭開始。

這對應 OpenAI 對 long tool-heavy workflows 的建議：明確 expected outcome、success criteria、allowed side effects、evidence rules 與 output shape [OpenAI Developers, 2026e,d,a]。

5.2 Mac ARM64 run: 更高環境摩擦下仍完成工程閉環

Mac ARM64 run 的起點更差：缺 Docker engine、qemu user-mode、gdb、capstone/pyelftools。GPT-5.5 先承認不能直接 official validate，再建立 Colima/QEMU/linux-amd64 runtime，重建 official-like IC，跑 baseline、排除 direct stack shellcode、進行 bounded text-section partial-return sweep，最後保存 validation artifact、sweep script、audit/handoff update、commit 與 push。

此 run 未完成 /shared/success.txt，但它把失敗路徑變成 future agent 可用的 negative evidence。這是 long-running harness 所重視的 incremental progress 與 durable artifact [Anthropic, 2026c,a]。

6 Codex hierarchical memory 是否為主因

答案是否定的：單一歸因不成立。

Codex 的 AGENTS.md hierarchy 是 instruction discovery 與 project guidance 合併機制，不是完整 episodic/task memory [OpenAI Developers, 2026b]。Codex agent loop 會把工具結果帶入後續模型輸入，長任務需要 compaction 或其他 context management [OpenAI, 2026, OpenAI Developers, 2026c]。但 compaction 只能緩解 context pressure，不保證保留 official validation 任務中最重要 failed hypotheses、negative evidence 與 proof boundary。

更精準的判斷：

```
Codex hierarchical instructions = task guidance layer
Codex compaction = context pressure relief
External progress artifacts = durable task memory
```

本次 Fugu Ultra memory 爆炸是三層疊加：

1. Codex 層：工具輸出與 shell logs 持續累積。

2. Fugu 層: multi-agent orchestration 增加分支、內部 retry 與 token 成本 [Sakana AI, 2026, Nielsen et al., 2026, Xu et al., 2026]。
3. Harness 層: 缺少 external checkpoint、progress ledger、failed hypothesis cache 與 no-new-evidence stop rule。

7 現有 AI Agent System 分析方法

7.1 Outcome Evaluation

Outcome evaluation 判斷最後環境是否達成目標。本案 outcome metric 很清楚: official IC-side workflow 是否產生 `/shared/success.txt`。三組 run 均未成立。

7.2 Process Evaluation

Process evaluation 檢查工具使用、規則遵守、重複探索、proof boundary 與行動是否逐步接近目標。OpenAI eval guidance 建議把 prompt、captured run、checks、score 串成可重跑評估 [OpenAI Developers, 2026d,a]。

7.3 Trace-based Evaluation

Trace-based evaluation 將模型輸出、工具呼叫、工具結果、檔案 side effects、git state 與 final state 全部作為評估對象。OpenAI trace grading 與 Anthropic agent eval 都強調 transcript/trajectory 層級診斷 [OpenAI Developers, 2026f, Anthropic, 2026b]。

7.4 Memory Evaluation

Agent memory 不只是長 context; 它是 write-manage-read loop。Memory survey 將機制分成 context-resident compression、retrieval stores、reflective memory、hierarchical virtual context 與 policy-learned management [Du, 2026]。AMA-Bench、MemoryAgentBench、Agentic Memory、Memory as Action、Memex(RL) 都指出長任務需要 selective memory、indexed evidence、learned context curation 與 selective forgetting [Zhao et al., 2026, Hu et al., 2026, Yu et al., 2026, Zhang et al., 2026, Wang et al., 2026]。

7.5 Long-Horizon Reliability

長任務不能只看 pass@1。Reliability Science Framework 提出 Reliability Decay Curve、Variance Amplification Factor、Graceful Degradation Score 與 Meltdown Onset Point, 用於分析長任務中 reliability decay 與 spiral/meltdown [Khanal et al., 2026]。本案的 repo-status regression 可視為 task-frame drift 與 meltdown onset 的候選訊號。

7.6 Native-runtime / Terminal Benchmarking

WildClawBench、Terminal-Bench、LongCLI-Bench 都指向同一件事: 真實 CLI、Docker、file system、shell side effects 與 hybrid grading 會揭露短 benchmark 看不到的 agent failure [Ding et al., 2026, Merrill et al., 2026, Feng et al., 2026]。Terminal-agent benchmark task guideline 進一步提

醒: benchmark 應 adversarial、difficult、legible, 避免 reward-hackable verification 與把 benchmark task 寫成幫助模型成功的 prompt [Bercovich, 2026]。

7.7 Safety / Proof Boundary Evaluation

ATBench-Codex 將 Codex-runtime trajectories 放進 safety taxonomy, 涵蓋 repositories、shells、patches、dependencies、approvals 與 runtime policy boundaries [Yang et al., 2026]。本案的 proof boundary 包含 sanity check、invalid proof、official validation 與 success claim 的分離。

7.8 Harness / Model Attribution

現代 agent evaluation 評估的是 model + harness + tools + memory + environment + grader, 而不是單一模型。Claude Code、Claude Cowork、OpenCode 等產品/系統也顯示 coding agent 與 knowledge-work agent 的差異常由 harness、tooling、artifact discipline 與 session continuation 決定 [Anthropic, 2026d,e, OpenCode, 2026, Calboreanu, 2026]。

8 17 筆最相近 reference 比較

Rank	Reference	相近原因	與本 case 的差異
1	WildClawBench [Ding et al., 2026]	native-runtime、CLI harness、真工具、長時程、side-effect grading。	Benchmark, 不是單一 Fugu/Codex failure forensics。
2	Terminal-Bench [Merrill et al., 2026]	hard realistic terminal tasks 與真實 CLI workflows。	偏通用 terminal benchmark, 不分析 opaque orchestrator。
3	LongCLI-Bench [Feng et al., 2026]	長時程 command-line programming、step-level scoring、fail-to-pass/pass-to-pass。	偏 programming benchmark。
4	ATBench-Codex [Yang et al., 2026]	Codex-runtime trajectory safety 與 rule boundary。	偏 safety taxonomy, 不直接處理 token explosion。
5	Beyond pass@1 [Khanal et al., 2026]	reliability decay、meltdown onset 與長任務可靠性。	偏跨任務統計, 不是單案鑑識。
6	Terminal-Agent Task Guideline [Bercovich, 2026]	adversarial/difficult/legible task design 與 reward hacking。	偏 benchmark authoring。
7	Agent evaluation survey [Yehudai et al., 2026]	planning、tool use、memory、benchmarks、cost、safety taxonomy。	Survey, 不提供具體 Fugu/Codex trace。
8	Memory survey [Du, 2026]	write–manage–read memory taxonomy。	不含本案 security-lab proof boundary。
9	AMA-Bench [Zhao et al., 2026]	long-horizon memory over agentic trajectories。	偏 memory QA, 不是 CLI task completion。
10	Memex(RL) [Wang et al., 2026]	indexed evidence memory + compact context。	偏 memory mechanism。

11	Memory as Action [Zhang et al., 2026]	context curation as action, 對應 attention dilution。	不處理 Codex shell side effects。
12	Agentic Memory [Yu et al., 2026]	unified LTM/STM memory management。	偏 learned memory policy。
13	MemoryAgentBench [Hu et al., 2026]	incremental multi-turn memory capability。	偏 multi-turn memory, 非 native runtime。
14	LLMA-Mem [Wu et al., 2026]	multi-agent memory scaling, team size vs time。	不處理 local Docker/debugger trace。
15	Conductor [Nielsen et al., 2026]	Fugu-like learned orchestration, worker selection, topology。	強調 benchmark gains, 不分析 runtime failure。
16	TRINITY [Xu et al., 2026]	evolved LLM coordinator, 多 role orchestration。	非 Codex CLI failure analysis。
17	Context Engineering / product harnesses [Calboreanu, 2026, Anthropic, 2026d,e, OpenCode, 2026]	context package, coding agent, knowledge-work agent, multi-provider harness。	偏 methodology/product, 不是 native-runtime benchmark。

9 文獻綜合：已有研究與本案例缺口

9.1 已有研究已接近本主題

目前已有研究能支撐本案的多數分析框架：

- **長時程 native-runtime benchmark**: WildClawBench、Terminal-Bench、LongCLI-Bench。
- **trajectory / safety evaluation**: ATBench-Codex、OpenAI trace grading、Anthropic evals。
- **agent memory**: Memory survey、AMA-Bench、Memex(RL)、Memory as Action、Agentic Memory、MemoryAgentBench、LLMA-Mem。
- **long-running harness**: Anthropic harnesses、OpenAI Codex loop、OpenAI compaction、OpenAI eval loop。
- **multi-agent orchestration**: Sakana Fugu、Conductor、TRINITY。
- **context engineering / cowork systems**: Context Engineering、Claude Code、Claude Cowork、OpenCode。

9.2 但尚未看到完全等同研究

本案例的獨特交會點是：

OpenAI-compatible opaque multi-agent orchestration endpoint, embedded inside Codex CLI, running a long-horizon tool-heavy coding/security task, evaluated by token usage, trace forensics, proof boundary, external artifact quality, negative evidence, and official success artifact closure.

換言之，既有研究能解釋本案，但本案本身仍有研究價值。它不是又一個 agent benchmark，而是針對 opaque orchestration model 在 native CLI harness 中的 failure forensics。

10 對 Sakana Fugu Ultra 的具體改善建議

10.1 Orchestration 層

- 暴露 subagent trace、routing decisions、recursive depth 與 per-branch token cost。
- 建立 branch-level failed hypothesis cache，避免多個 worker 重試同一死路。
- 加入 no-new-evidence detector：連續三次沒有新 verified evidence 時停止探索並重寫 plan。
- 在每 15-20 次 tool call 後自動輸出 compact state：CURRENT_OBJECTIVE、VERIFIED_FACTS、FAILED_PATHS、OPEN_HYPOTHESES、NEXT_ACTIONS。
- 將 proof classification 做成 hard policy：FACT、THEORY、INVALID、OFFICIAL_SUCCESS。

10.2 Codex integration 層

- 提供 Codex-specific mode，限制 raw shell output 進 active context。
- 將大型 objdump/gdb/Docker/libc logs 存為 evidence files，只回傳 summary、decision impact 與 next action。
- 在 compaction 前強制寫出 human-auditable state summary。
- 每個 phase 必須回到 official success criterion 或明確說明為何不能驗證。

10.3 使用者 harness 層

建議建立：

```
PHASE2_PROGRESS.md
FAILED_HYPOTHESES.md
VALIDATION_LOG.md
phase2_state.json
EVIDENCE_INDEX.md
```

phase2_state.json 的最低欄位應包含 objective、success definition、invalid proofs、verified facts、failed hypotheses、open hypotheses、current blocker、next actions、last new evidence 與 stop conditions。

11 下一輪公平實驗設計

目前三份紀錄不是公平同題 benchmark。建議下一輪使用同一 prompt、同一 repo snapshot、同一 host 或明確 host matrix，並將 Fugu/GPT/Claude/OpenCode 類系統放入同一 protocol：

測試	模型	起點	任務	目的
A	Fugu Ultra	clean repo	direct completion	重現 baseline。
B	GPT-5.5	clean repo	direct completion	公平比較 direct solve。
C	Fugu Ultra	HANDOFF_ PHASE2.md	continue completion	測試 Fugu 是否受益於 external memory。
D	GPT-5.5	HANDOFF_ PHASE2.md	continue completion	continuation baseline。
E	Fugu Ultra	failed trace	handoff-only	公平測 Fugu state compression。
F	GPT-5.5	failed trace	handoff-only	對照 memory repair。
G	Fugu Ultra	Mac ARM64 + same handoff	environment repair + validation	測跨環境穩定性。
H	GPT-5.5	Mac ARM64 + same handoff	environment repair + validation	已有近似 baseline。

主要 metrics:

- official success rate;
- false completion rate;
- tokens per useful evidence;
- duplicate command rate;
- failed hypothesis retry rate;
- no-new-evidence streak;
- drift point / meltdown onset point;
- artifact quality;
- repo hygiene;
- time-to-first-valid-evidence;
- time-to-official-validation。

12 後續研究方向

FIRST PRINCIPLE 判斷：本研究線的稀缺資源不是更多模型輸出或更多候選任務，而是可被信任的長時間任務狀態。研究主軸應收斂為：

Long-Horizon Stateful Agent Reliability

更具體地說：

Long-Horizon Stateful AI Agents for Real-World Cybersecurity and Software Engineering Tasks

完整路線圖保存於 packet 根目錄：

future-research-directions.md

最值得優先發展的五條路線如下：

路線	核心問題	最小研究嘗試
Failure taxonomy	長任務 agent 如何失敗	將 Fugu/GPT-5.5 traces 標註為 state fragmentation、recursive rediscovery、token amplification、proof-boundary drift 等 failure types。
External memory protocol	context window 如何變成 project memory	設計 STATE.md、FAILED_HYPOTHESES.md、EVIDENCE_INDEX.md，比較 no-memory vs artifact-memory runs。
Drift / meltdown detector	何時該停止或人類介入	計算 duplicate command rate、no-new-evidence streak、objective-distance、repo-inspection regression。
Model + harness study	差異來自模型還是 harness	用同一 prompt / repo snapshot / tool budget 比較 Fugu、GPT-5.5、Claude/OpenCode 類 agent。
Stateful cybersecurity agent evaluation	資安 agent 如何守住 proof boundary	分開 sanity check、invalid proof、official validation、partial progress 與 success claim。

建議下一個 durable artifact 是 agent_behavior_eval_protocol.md。它應包含任務定義、official success oracle、允許/禁止的 proof 類型、外部記憶 artifact、drift/loop/token 指標、model comparison matrix、scoring rubric 與最小可重複實驗流程。

13 專業行為分析句型

13.1 觀察型

- 模型在任務初期呈現高探索密度，能快速掃描 repo、文件、lab 結構與執行環境。

- 工具呼叫序列顯示模型具備多工具操作能力，涵蓋 shell、Docker、binary inspection、debugger 與 script-based probing。
- 模型多次取得有效中間證據，但未將證據整理成穩定任務狀態。

13.2 推論型

- 此行為顯示模型 local reasoning 尚可，global task-state management 較弱。
- 模型未能把已知失敗假設寫入外部記憶，後續行動產生重新探索與低效率重複。
- 這不是單純工具失敗；它是 evidence-to-decision pipeline 的斷裂。

13.3 風險型

- 若缺少 progress ledger 與 stop condition，Fugu Ultra 的 recursive orchestration 可能把正常探索放大成 token explosion。
- 大量 raw tool output 進入 context 後，重要資訊仍在上下文中，卻不再被有效使用，形成 context rot。

13.4 改進型

- 建議將任務拆成 deterministic validation phases，並要求模型每完成一個 phase 就更新 `phase2_state.json`。
- 建議限制每個 hypothesis 的工具呼叫次數；若三次驗證沒有新資訊，模型必須停止、摘要、重排優先順序。
- 建議把大型輸出改為 file-backed evidence，只把摘要、offset、symbol、crash signature 放進 active context。

14 結論

本次三份紀錄的最強結論不是「GPT-5.5 已證明比 Fugu Ultra 更會解 exploit」。三組 run 都沒有完成 official IC-side `/shared/success.txt`。真正被證明的是：

Fugu Ultra 在 Ubuntu native Codex CLI 長時間任務中展現強探索與弱收斂；GPT-5.5 在 Ubuntu handoff run 中完成 state compression，在 Mac ARM64 run 中完成環境修復、deeper negative validation、artifact 保存與 repo hygiene。

因此，這次差異的核心不是單純 hierarchical memory，也不是單純模型智力，而是 long-horizon state discipline、context engineering、artifact discipline 與 proof boundary。Fugu Ultra 若要在 Codex CLI 長任務中穩定運作，必須把內部 orchestration 變得可觀測，並把 Codex session context 之外的 project memory 做硬：progress files、failed hypotheses、phase gates、validation logs、tool-output summarization 與 budget-aware loop control。

A 已下載 reference 檔案清單

No.	Reference	Local PDF path
1	WildClawBench	../references/papers/arxiv-2605.10912-wildclawbench.pdf
2	Terminal-Bench	../references/papers/arxiv-2601.11868-terminal-bench.pdf
3	LongCLI-Bench	../references/papers/arxiv-2602.14337-longcli-bench.pdf
4	ATBench-Codex	../references/papers/arxiv-2604.14858-atbench-codex.pdf
5	Reliability Science Framework	../references/papers/arxiv-2603.29231-reliability-science-framework.pdf
6	Terminal-Agent Benchmark Task Guideline	../references/papers/arxiv-2604.28093-terminal-agent-benchmark-task-guideline.pdf
7	Survey on Evaluation of LLM-based Agents	../references/papers/arxiv-2503.16416-agent-evaluation-survey.pdf
8	Memory for Autonomous LLM Agents	../references/papers/arxiv-2603.07670-memory-survey.pdf
9	AMA-Bench	../references/papers/arxiv-2602.22769-ama-bench.pdf
10	Memex(RL)	../references/papers/arxiv-2603.04257-memex-rl.pdf
11	Memory as Action	../references/papers/arxiv-2510.12635-memory-as-action.pdf
12	Agentic Memory	../references/papers/arxiv-2601.01885-agentic-memory.pdf
13	MemoryAgentBench	../references/papers/arxiv-2507.05257-memoryagentbench.pdf
14	LLMA-Mem	../references/papers/arxiv-2604.03295-llma-mem.pdf
15	Conductor	../references/papers/arxiv-2512.04388-conductor.pdf
16	TRINITY	../references/papers/arxiv-2512.04695-trinity.pdf
17	Context Engineering	../references/papers/arxiv-2604.04258-context-engineering.pdf

参考文献

- Anthropic. Effective context engineering for ai agents, 2026a. URL <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>. Engineering guidance.
- Anthropic. Demystifying evals for ai agents, 2026b. URL <https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents>. Engineering guidance.
- Anthropic. Effective harnesses for long-running agents, 2026c. URL <https://www.anthropic.com/engineering/effective-harnesses-for-long-running-agents>. Engineering guidance.
- Anthropic. Claude code, 2026d. URL <https://www.anthropic.com/product/claude-code>. Product page.
- Anthropic. Claude cowork, 2026e. URL <https://www.anthropic.com/product/claude-cowork>. Product page.
- Ivan Bercovich. What makes a good terminal-agent benchmark task: A guideline for adversarial, difficult, and legible evaluation design, 2026. URL <https://arxiv.org/abs/2604.28093>.
- Elias Calboreanu. Context engineering: A practitioner methodology for structured human-ai collaboration, 2026. URL <https://arxiv.org/abs/2604.04258>.
- Shuangrui Ding, Xuanlang Dai, Long Xing, Shengyuan Ding, Ziyu Liu, JingYi Yang, Penghui Yang, Zhixiong Zhang, Xilin Wei, Xinyu Fang, Yubo Ma, Haodong Duan, Jing Shao, Jiaqi Wang, Dahua Lin, Kai Chen, and Yuhang Zang. Wildclawbench: A benchmark for real-world, long-horizon agent evaluation, 2026. URL <https://arxiv.org/abs/2605.10912>.
- Pengfei Du. Memory for autonomous llm agents: Mechanisms, evaluation, and emerging frontiers, 2026. URL <https://arxiv.org/abs/2603.07670>.
- Yukang Feng, Jianwen Sun, Zelai Yang, Jiaxin Ai, Chuanhao Li, Zizhen Li, Fanrui Zhang, Kang He, Rui Ma, Jifan Lin, et al. Longcli-bench: A preliminary benchmark and study for long-horizon agentic programming in command-line interfaces, 2026. URL <https://arxiv.org/abs/2602.14337>.
- Yuanzhe Hu, Yu Wang, and Julian McAuley. Evaluating memory in llm agents via incremental multi-turn interactions, 2026. URL <https://arxiv.org/abs/2507.05257>.
- Aaditya Khanal, Yangyang Tao, and Junxiu Zhou. Beyond pass@1: A reliability science framework for long-horizon llm agents, 2026. URL <https://arxiv.org/abs/2603.29231>.
- Mike A. Merrill, Alexander G. Shaw, Nicholas Carlini, Boxuan Li, Harsh Raj, Ivan Bercovich, Lin Shi, Jeong Yeon Shin, Thomas Walshe, E. Kelly Buchanan, et al. Terminal-bench: Benchmarking agents on hard, realistic tasks in command line interfaces, 2026. URL <https://arxiv.org/abs/2601.11868>.

- Stefan Nielsen, Edoardo Cetin, Peter Schwendeman, Qi Sun, Jinglue Xu, and Yujin Tang. Learning to orchestrate agents in natural language with the conductor, 2026. URL <https://arxiv.org/abs/2512.04388>.
- OpenAI. Unrolling the codex agent loop, 2026. URL <https://openai.com/index/unrolling-the-codex-agent-loop/>. Official Codex engineering article.
- OpenAI Developers. Build an agent improvement loop with traces, evals, and codex, 2026a. URL https://developers.openai.com/cookbook/examples/agents_sdk/agent_improvement_loop. Official cookbook.
- OpenAI Developers. Custom instructions with agents.md, 2026b. URL <https://developers.openai.com/codex/guides/agents-md/>. Official Codex documentation.
- OpenAI Developers. Compaction, 2026c. URL <https://developers.openai.com/api/docs/guides/compaction>. Official API guide.
- OpenAI Developers. Testing agent skills systematically with evals, 2026d. URL <https://developers.openai.com/blog/eval-skills>. Official agent evaluation guidance.
- OpenAI Developers. Using gpt-5.5, 2026e. URL <https://developers.openai.com/api/docs/guides/latest-model>. Official model guide.
- OpenAI Developers. Trace grading, 2026f. URL <https://developers.openai.com/api/docs/guides/trace-grading>. Official trace-evaluation guidance.
- OpenCode. Opencode, 2026. URL <https://opencode.ai/>. Open-source coding agent product page.
- Sakana AI. Sakana fugu: A multi-agent orchestration system as a foundation model, 2026. URL <https://sakana.ai/fugu-beta/>. Official product and beta announcement.
- Zhenting Wang, Huancheng Chen, Jiayun Wang, and Wei Wei. Memex(rl): Scaling long-horizon llm agents via indexed experience memory, 2026. URL <https://arxiv.org/abs/2603.04257>.
- Shanglin Wu, Yuyang Luo, Yueqing Liang, Kaiwen Shi, Yanfang Ye, Ali Payani, and Kai Shu. Scaling teams or scaling time? memory enabled lifelong learning in llm multi-agent systems, 2026. URL <https://arxiv.org/abs/2604.03295>.
- Jinglue Xu, Qi Sun, Peter Schwendeman, Stefan Nielsen, Edoardo Cetin, and Yujin Tang. Trinity: An evolved llm coordinator, 2026. URL <https://arxiv.org/abs/2512.04695>.
- Zhonghao Yang, Yu Li, Yanxu Zhu, Tianyi Zhou, Yuejin Xie, Haoyu Luo, Jing Shao, Xia Hu, and Dongrui Liu. Benchmarks for trajectory safety evaluation and diagnosis in openclaw and codex: Atbench-claw and atbench-codex, 2026. URL <https://arxiv.org/abs/2604.14858>.
- Asaf Yehudai, Lilach Eden, Alan Li, Guy Uziel, Yilun Zhao, Roy Bar-Haim, Arman Cohan, and Michal Shmueli-Scheuer. Survey on evaluation of llm-based agents, 2026. URL <https://arxiv.org/abs/2503.16416>.

- Yi Yu, Liuyi Yao, Yuexiang Xie, Qingquan Tan, Jiaqi Feng, Yaliang Li, and Libing Wu. Agentic memory: Learning unified long-term and short-term memory management for large language model agents, 2026. URL <https://arxiv.org/abs/2601.01885>.
- Yuxiang Zhang, Jiangming Shu, Ye Ma, Xueyuan Lin, Shangxi Wu, and Jitao Sang. Memory as action: Autonomous context curation for long-horizon agentic tasks, 2026. URL <https://arxiv.org/abs/2510.12635>.
- Yujie Zhao, Boqin Yuan, Junbo Huang, Haocheng Yuan, Zhongming Yu, Haozhou Xu, Lanxiang Hu, Abhilash Shankarampeta, Zimeng Huang, Wentao Ni, Yuandong Tian, and Jishen Zhao. Ama-bench: Evaluating long-horizon memory for agentic applications, 2026. URL <https://arxiv.org/abs/2602.22769>.